Klasifikasi Kelayakan Mobil dengan Perceptron dan ADALINE

Studi kasus Car Evaluation (UCI): Tugas Besar 1

Kelompok TrioMacan

Sthacya Marela Elsithalia Lakamola (71241106)

Sandy Rehan Linta' (71241144)

Yosiabes Priarsono (71241147)

1. Masalah dan tujuan

Pada Tugas 1 kelompok merumuskan kasus *apakah sebuah mobil layak dipilih calon pembeli berdasarkan enam kriteria* (harga beli, biaya perawatan, jumlah pintu, kapasitas penumpang, ukuran bagasi, keselamatan) sebagai **supervised learning** klasifikasi empat kelas dengan MLP. Pada TB1 kasus itu dipersempit menjadi **klasifikasi dua kelas** dengan neuron tunggal: masukan $\mathbf{x} \in \mathbb{R}^{21}$ (6 fitur kategorikal dalam bentuk one-hot), target $y \in \{-1, +1\}$, kelas positif (+1) = **acc** (layak), kelas negatif (−1) = **unacc** (tidak layak).

Tujuan: (1) mengimplementasikan Perceptron dan ADALINE (Delta Rule) sendiri dengan NumPy; (2) membandingkan proses belajar keduanya pada delapan konfigurasi terkendali (η dan standardisasi);
(3) menilai indikasi keterpisahan linear data; (4) menjelaskan hasil berdasarkan bukti, bukan hanya akurasi. Seperti pada Tugas 1, kesalahan paling berbahaya ialah **mobil tidak layak diprediksi layak**, yaitu *false positive* kelas acc; karena itu precision kelas positif dilaporkan di samping recall dan F1.

2. Dataset dan kaitannya dengan Tugas 1

Aspek	Keterangan
Sumber dan izin	UCI Machine Learning Repository, *Car Evaluation* (Bohanec & Rajkovic; didonasikan 1997); lisensi CC BY 4.0. Tidak ada data pribadi.
Asal label	Model keputusan hierarkis DEX (aturan pakar), bukan survei pembeli sungguhan.
Observasi	1.728 data penuh (seluruh 4·4·4·3·3·3 kombinasi atribut); **1.594** dipakai (unacc 1.210 + acc 384).
Fitur (6, kategorikal)	buying {vhigh, high, med, low}; maint {vhigh, high, med, low}; doors {2, 3, 4, 5more}; persons {2, 4, more}; lug_boot {small, med, big}; safety {low, med, high}.
Label dan distribusi	acc → +1 (24,1%), unacc → −1 (75,9%). Baseline “selalu unacc” = 0,7586. Kelas timpang, sehingga precision, recall, dan F1 kelas positif dilaporkan.
Missing value, duplikasi	Tidak ada missing value; tidak ada baris duplikat, sehingga imputasi tidak diperlukan.
Transformasi	One-hot: 6 fitur → 21 kolom 0/1 (sama seperti Tugas 1); standardisasi z-score dari data latih saja.

Pemilihan dua kelas. Dipakai unacc vs acc karena (i) keduanya kelas terbesar sehingga data cukup (1.594 ≥ 100); (ii) good (69) dan vgood (65) terlalu sedikit (pada Tugas 1 hanya ±10 sampel di data uji sehingga metriknya tidak stabil); (iii) keputusan inti kasus ini ialah layak atau tidak layak dibeli. Konsekuensinya, eksperimen ini **bukan** masalah empat kelas penuh. **Yang dipertahankan dari Tugas 1:** dataset, enam fitur, one-hot 21 kolom, split berstrata, perhatian pada kelas timpang. **Yang berubah:** model (MLP softmax → neuron tunggal), kelas (4 → 2), split 70/15/15 → 80:20 (TB1 tidak memilih model sehingga tidak memerlukan data validasi).

Catatan asal berkas. Berkas data dibentuk dari tabel aturan DEX yang dipublikasikan dan dicocokkan dengan car.data asli UCI memakai scripts/verifikasi_car_data.py; hasil verifikasi dicatat pada README repository.

3. Artikel dan kode pendukung

Sumber	Jenis	Kontribusi / adaptasi
Bohanec & Rajkovic (1990), *Expert system for decision making*	Artikel (kasus)	Asal dataset: label dari aturan bertingkat DEX (harga → teknis → kelayakan), sehingga hubungan fitur–label tidak diharapkan sepenuhnya aditif. Ini diuji (bagian 6 dan 7), bukan diasumsikan.
Zupan dkk. (1997), *Machine learning by function decomposition*	Artikel (kasus)	Menunjukkan model hierarkis dapat direkonstruksi sepenuhnya: data deterministik, tanpa derau, sehingga galat model linear mencerminkan keterbatasan kapasitas model. Hanya konteks; model utama tetap Perceptron dan ADALINE.
Rosenblatt (1958); Widrow & Hoff (1960)	Artikel (metode)	Dasar aturan Perceptron dan Delta Rule / LMS.
Raschka, *Adaline* (dokumentasi mlxtend)	Dokumentasi kode	**Diadaptasi:** pola batch gradient descent ($e = y - z$; $w \mathrel{+}= \eta \cdot X^T e/n$). **Diubah:** pembaruan bias mengikuti panduan; $J = (1/2n)\Sigma e^2$ (bukan SSE); berhenti bila J inf/NaN dengan epoch dicatat; riwayat bobot dan akurasi per epoch. mlxtend tidak dipakai untuk pelatihan.

4. Model neuron dan aturan pembelajaran

Kedua model memakai neuron $z = w^T x + b$ dan keputusan $\hat{y} = +1$ jika $z \geq 0$, $\hat{y} = -1$ jika $z < 0$. Bobot **w** menentukan arah batas keputusan (pada one-hot: satu bobot per nilai atribut), bias **b** menggeser hyperplane $w^T x + b = 0$, dan η adalah laju belajar. Inisialisasi $w = 0$, $b = 0$; urutan sampel tetap seperti pada data latih (tanpa *shuffle*); 50 epoch.

	Perceptron (per sampel)	ADALINE (batch, Delta Rule)
Error	Diskret: $y - \hat{y} \in \{0, \pm 2\}$	Kontinu dari keluaran linear: $e = y - z$
Pembaruan	$\Delta = \eta(y - \hat{y})$; $w \leftarrow w + \Delta x$; $b \leftarrow b + \Delta$	$w \leftarrow w + \eta \cdot X^T e/n$; $b \leftarrow b + \eta \cdot \text{mean}(e)$
Kapan bobot berubah	Hanya pada sampel yang salah klasifikasi	Setiap epoch, dari semua sampel (juga yang sudah benar tetapi $\lvert z \rvert < 1$)
Fungsi objektif	Tidak ada; dicatat jumlah pembaruan salah per epoch	$J = (1/2n)\Sigma(y_i - z_i)^2$; MSE = 2J; dicatat *sesudah* pembaruan di akhir epoch
Ambang kelas	Dipakai saat belajar dan prediksi	Hanya saat prediksi

Perhitungan manual. Dua langkah pembaruan Perceptron dan dua iterasi batch ADALINE dihitung tangan pada data mini (Lampiran A) dan pada dua sampel data mobil nyata (Lampiran B); keduanya diperiksa dengan assert terhadap kelas Perceptron dan Adaline di notebook. Bobot dan bias akhir hitungan manual data mini: Perceptron $w = (0{,}2; -0{,}2)$, $b = 0$; ADALINE $w = (0{,}139375; -0{,}053125)$, $b = -0{,}005$.

5. Penyiapan data dan rancangan eksperimen

- **Split:** 80:20 berstratifikasi, random_state = 42: latih 1.275 (+1: 307, −1: 968), uji 319 (+1: 77, −1: 242). Split yang sama untuk semua model dan konfigurasi.
- **Tanpa kebocoran:** mean dan simpangan baku standardisasi dipelajari hanya dari data latih. Domain nilai atribut tetap (ditentukan definisi dataset), sehingga one-hot tidak membocorkan data.
- **Konfigurasi ditetapkan sebelum evaluasi uji.** Data uji hanya untuk pelaporan; tidak ada pemilihan model atau η terbaik, sehingga data validasi tidak diperlukan. Diagnostik tambahan memakai data latih saja.
- **Divergen:** bila J atau parameter ADALINE menjadi inf/NaN, pelatihan dihentikan dan epoch dicatat (tidak terjadi pada kedelapan pelatihan).

#	Model	η	Epoch	Standardisasi
1	Perceptron	0,001	50	Ya
2	Perceptron	0,01	50	Ya
3	Perceptron	0,1	50	Ya
4	ADALINE	0,001	50	Ya
5	ADALINE	0,01	50	Ya
6	ADALINE	0,1	50	Ya
7	Perceptron	0,01	50	Tidak
8	ADALINE	0,01	50	Tidak

Tabel 1. Delapan pelatihan. Inisialisasi, urutan sampel, dan split dipertahankan agar pengaruh skala fitur dapat dibandingkan.

6. Hasil

6.1 Tabel seluruh konfigurasi

Model	η	Std	Akurasi latih	Akurasi uji	Galat latih akhir	Pembaruan ep-50 / J akhir (MSE = 2J)
Perceptron	0,001	Ya	0,9200	0,9028	0,0800	97 pembaruan
Perceptron	0,01	Ya	0,9200	0,9028	0,0800	97 pembaruan
Perceptron	0,1	Ya	0,9200	0,9028	0,0800	97 pembaruan
ADALINE	0,001	Ya	0,8988	0,8683	0,1012	J = 0,4663 (MSE 0,9325)
ADALINE	0,01	Ya	0,9169	0,8934	0,0831	J = 0,2903 (MSE 0,5806)
ADALINE	0,1	Ya	0,9412	0,9467	0,0588	J = 0,1938 (MSE 0,3876)
Perceptron	0,01	Tidak	0,9043	0,8746	0,0957	105 pembaruan
ADALINE	0,01	Tidak	0,7592	0,7586	0,2408	J = 0,3279 (MSE 0,6558)

Tabel 2. Akurasi memakai keluaran ambang. Baseline “selalu unacc” pada data uji = 0,7586. J ADALINE dicatat sesudah pembaruan epoch ke-50.

6.2 Kondisi pada epoch ke-10, ke-30, dan ke-50

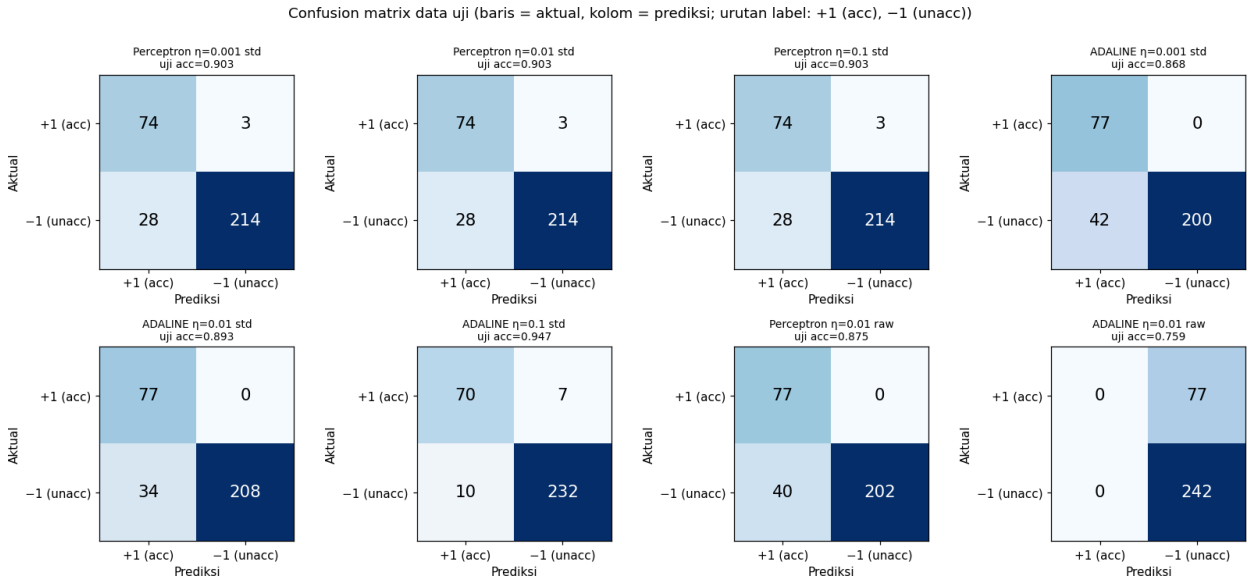
Konfigurasi	Pembaruan salah / J (ep 10)	(ep 30)	(ep 50)	Akurasi latih (ep 10)	(ep 30)	(ep 50)
Perceptron η = 0.001 std.	96	97	97	0,9255	0,9200	0,9200
Perceptron η = 0.01 std.	96	97	97	0,9255	0,9200	0,9200
Perceptron η = 0.1 std.	96	97	97	0,9255	0,9200	0,9200
ADALINE η = 0.001 std.	0,4929	0,4793	0,4663	0,8973	0,8980	0,8988
ADALINE η = 0.01 std.	0,4360	0,3462	0,2903	0,9004	0,9098	0,9169
ADALINE η = 0.1 std.	0,2218	0,1941	0,1938	0,9333	0,9404	0,9412
Perceptron η = 0.01 tanpa std.	98	99	105	0,9325	0,9325	0,9043
ADALINE η = 0.01 tanpa std.	0,4312	0,3607	0,3279	0,7592	0,7592	0,7592

Tabel 3. Perceptron: jumlah pembaruan salah pada epoch tersebut; ADALINE: J sesudah pembaruan.

6.3 Confusion matrix, precision, recall, F1 (kelas positif = acc)

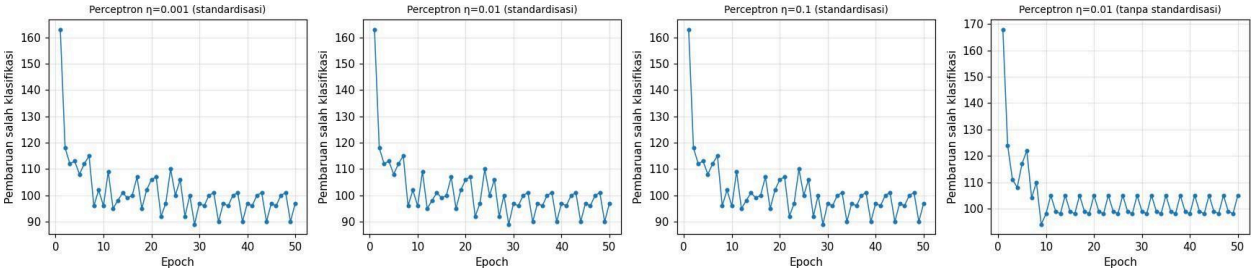
Konfigurasi	TP	FN	FP	TN	Precision	Recall	F1
Perceptron η = 0.001 std.	74	3	28	214	0,726	0,961	0,827
Perceptron η = 0.01 std.	74	3	28	214	0,726	0,961	0,827
Perceptron η = 0.1 std.	74	3	28	214	0,726	0,961	0,827
ADALINE η = 0.001 std.	77	0	42	200	0,647	1,000	0,786
ADALINE η = 0.01 std.	77	0	34	208	0,694	1,000	0,819
ADALINE η = 0.1 std.	70	7	10	232	0,875	0,909	0,892
Perceptron η = 0.01 tanpa std.	77	0	40	202	0,658	1,000	0,794
ADALINE η = 0.01 tanpa std.	0	77	0	242	0,000	0,000	0,000

*Tabel 4. Urutan label [+1 (acc), −1 (unacc)]; baris = aktual, kolom = prediksi. TP = acc terdeteksi, FN = acc terlewat, **FP = unacc dikira acc (kesalahan berbahaya)**, TN = unacc benar.*

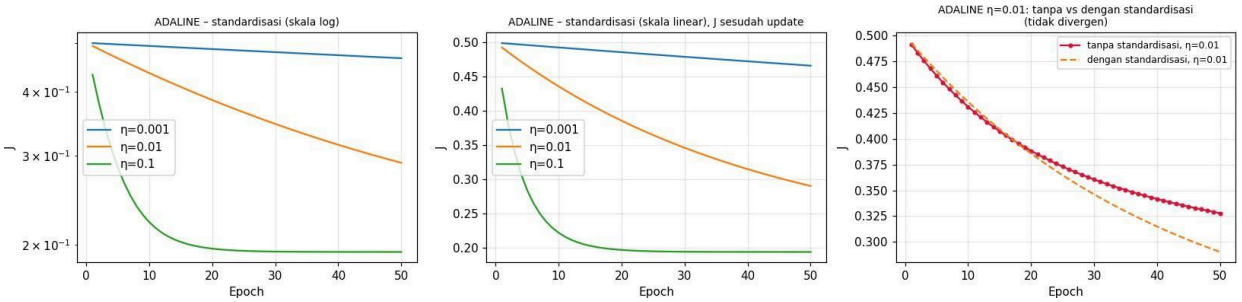


Gambar 1. Confusion matrix data uji untuk delapan konfigurasi (urutan label +1 (acc), −1 (unacc)).

6.4 Kurva pelatihan dan kesalahan latih akhir



Gambar 2. Jumlah pembaruan salah klasifikasi per epoch (Perceptron). Tiga η terstandardisasi menghasilkan kurva identik.



Gambar 3. J per epoch (ADALINE): skala log dan linear untuk tiga η, serta perbandingan η = 0,01 tanpa dan dengan standardisasi.

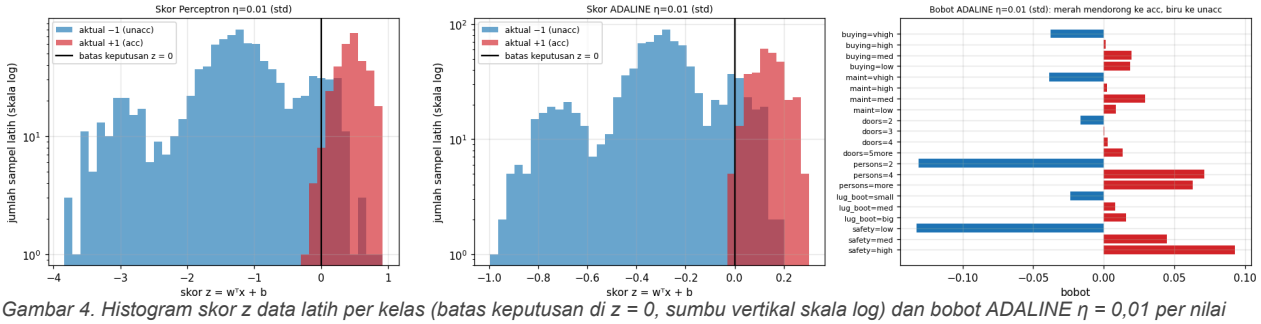
Kesalahan latih setelah epoch terakhir (1 − akurasi latih): Perceptron 0,0800 (η = 0,001; 0,01; 0,1, standardisasi) dan 0,0957 (tanpa standardisasi); ADALINE 0,1012; 0,0831; 0,0588 (η = 0,001; 0,01; 0,1, standardisasi) dan 0,2408 (tanpa standardisasi).

6.5 Bobot dan bias akhir

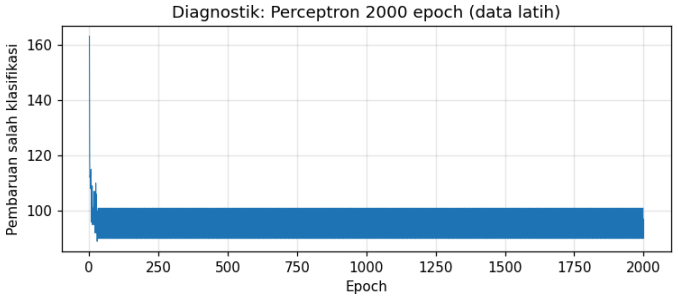
Konfigurasi	$\|w\|_2$	Bias b
Perceptron η = 0.001 std.	0,0968	-0,0860
Perceptron η = 0.01 std.	0,9681	-0,8600
Perceptron η = 0.1 std.	9,6806	-8,6000
ADALINE η = 0.001 std.	0,0324	-0,0253
ADALINE η = 0.01 std.	0,2458	-0,2048
ADALINE η = 0.1 std.	0,5192	-0,5158
Perceptron η = 0.01 tanpa std.	0,7009	-0,0600
ADALINE η = 0.01 tanpa std.	0,2416	-0,1401

Tabel 5. Norma bobot dan bias akhir semua konfigurasi; 21 bobot per konfigurasi pada Lampiran C dan results/bobot_bias_akhir.csv.

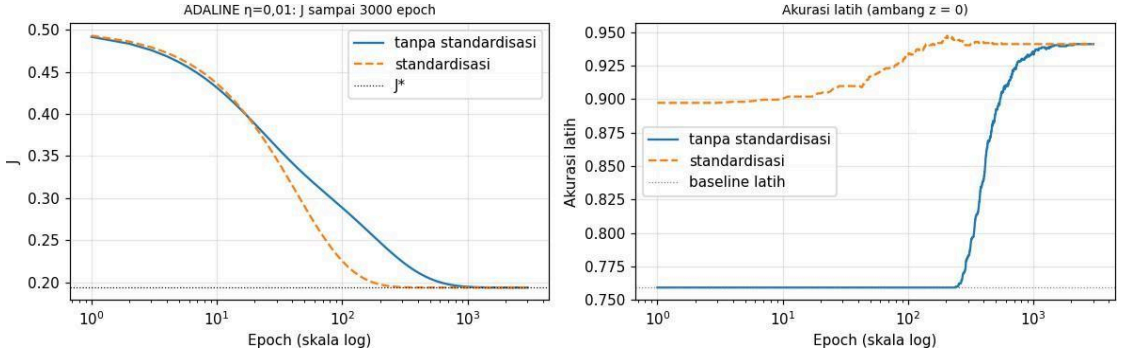
Dengan 21 fitur one-hot, batas keputusan adalah hyperplane berdimensi 20 dan tidak dapat digambar pada dua fitur (fitur biner hanya membentuk beberapa titik). Proyeksi yang setia adalah **skor z = $\mathbf{w}^T\mathbf{x}$ + b**, karena batas keputusan tepat berada di z = 0.



Gambar 4. Histogram skor z data latih per kelas (batas keputusan di z = 0, sumbu vertikal skala log) dan bobot ADALINE η = 0,01 per nilai atribut.



Gambar 5. Diagnostik: Perceptron 2.000 epoch pada data latih terstandardisasi; jumlah pembaruan tidak pernah mencapai nol.



Gambar 6. Diagnostik: ADALINE η = 0,01 sampai 3.000 epoch, tanpa dan dengan standardisasi (hanya data latih).

7. Pembahasan dan keterbatasan

(a) Keterpisahan linear. Data **tidak** menunjukkan keterpisahan linear. Uji pasti dengan *linear programming* (mencari w, b dengan $y_i(w^T x_i + b) \geq 1$ untuk semua sampel latih) menyatakan sistem *infeasible*. Perilaku pelatihan konsisten: pada 2.000 epoch Perceptron tidak pernah mencapai nol pembaruan (minimum 89 pada epoch 29; 97 pada epoch 50 dan epoch 2.000; akurasi latih tertinggi
±0,94), sehingga teorema konvergensi Perceptron tidak berlaku. Histogram skor memperlihatkan kedua kelas tumpang tindih di sekitar z = 0. Bobot terbesar (persons=2 dan safety=low sangat negatif) sejalan dengan aturan pakar yang membuat dua kondisi itu selalu menghasilkan unacc (aturan "veto" yang dapat didekati secara linear), sedangkan syarat acc yang melibatkan kombinasi harga dan teknis tidak dapat ditangkap sempurna. Bagian terakhir ini adalah *interpretasi* kelompok; yang dibuktikan hanyalah ketidakterpisahan.

(b) Perbedaan error. Perceptron memakai error diskret $y - \hat{y} \in \{0, \pm 2\}$: bobot berubah hanya pada sampel yang salah, dengan langkah yang tidak bergantung pada jarak sampel ke batas. ADALINE memakai error kontinu e = y − z pada *semua* sampel, sehingga meminimalkan J. Pada η = 0,1, J turun dari 0,500 ke 0,222 (epoch 10), 0,194 (epoch 30), dan 0,1938 (epoch 50), sama dengan J^* kuadrat terkecil (0,1938): ADALINE telah mencapai optimumnya. Jumlah kesalahan Perceptron berfluktuasi (163 pada epoch 1; 96; 97; 97) karena tidak ada fungsi objektif yang dijamin turun. J minimal tidak otomatis meminimalkan kesalahan klasifikasi.

(c) Pengaruh η, epoch, dan standardisasi.

- **η pada Perceptron: hasil identik.** Ketiga η menghasilkan 97 pembaruan, akurasi latih 0,9200, akurasi uji 0,9028, dan confusion matrix sama. Sebabnya inisialisasi nol, urutan tetap, dan η konstan positif: η hanya menskalakan w dan b (rasio w(η = 0,01)/w(η = 0,001) = 10 dan w(η = 0,1)/w(η = 0,001) = 100; ‖w‖ = 0,097 / 0,97 / 9,7), sehingga tanda z dan semua prediksi tidak berubah. Ini sah, bukan galat kode.
- **η pada ADALINE: berpengaruh besar.** J epoch 50 = 0,466 / 0,290 / 0,194 dan akurasi uji 0,868 / 0,893 / 0,947 untuk η = 0,001 / 0,01 / 0,1. Dua η kecil belum konvergen pada epoch 50 (J masih turun; $J^* = 0{,}194$). Semua η berada di bawah batas kestabilan $2/\lambda_{max} = 1{,}20$ (data standardisasi), sehingga tidak ada divergensi.
- **Epoch.** Untuk ADALINE, epoch tambahan menurunkan J hingga J^* (η = 0,1 tercapai sekitar epoch 30); untuk Perceptron, epoch tambahan tidak membantu.
- **Standardisasi: mempercepat, bukan mengubah tujuan.** One-hot sudah berskala 0/1 sehingga tidak ada risiko ledakan; ADALINE tanpa standardisasi tidak divergen (η = 0,01 < batas 0,725). Namun ia jauh lebih lambat karena kondisi numerik ($\kappa = \lambda_{max}/\lambda_{min} = 13{,}3$ tanpa vs 1,67 dengan standardisasi): pada epoch 50 akurasi latihnya 0,759 (sama dengan baseline) dan tidak pernah memprediksi acc. Diagnostik 3.000 epoch pada data latih (Gambar 6) menunjukkan model itu baru memprediksi acc pada epoch 240, mencapai $J \leq 1{,}01\, J^*$ pada epoch 841 (dengan standardisasi: epoch 230), dan akhirnya sampai ke J^* dengan akurasi latih 0,9412, sama dengan model terstandardisasi. Pada Perceptron standardisasi mengubah bobot relatif antar kolom, sehingga hasil sedikit berbeda (akurasi uji 0,875 tanpa vs 0,903 dengan).

(d) Akurasi sama bukan berarti proses belajar sama. ADALINE tanpa standardisasi memiliki akurasi uji 0,7586 (= baseline) padahal J-nya sudah turun dari 0,500 ke 0,328: ia belajar, tetapi keluaran ambangnya belum berbeda dari model trivial. Perceptron (akurasi uji 0,903; recall 0,961; precision 0,726; **28 FP**) dan ADALINE η = 0,1 (0,947; recall 0,909; precision 0,875; **10 FP**) juga memiliki profil kesalahan berbeda. Karena FP adalah kesalahan paling berbahaya pada kasus ini, profil kesalahan lebih penting daripada angka akurasi. ADALINE η = 0,1 terlihat terbaik pada data uji (17 salah vs 31 salah pada Perceptron), tetapi ini **laporan konfigurasi yang sudah ditetapkan, bukan hasil seleksi**, dan belum diuji secara statistik.

(e) Kolinearitas one-hot. Setiap grup one-hot berjumlah 1, sehingga kolom redundan dengan bias: matriks [X 1] hanya berperingkat 16 dari 22 kolom. Bobot karenanya tidak unik; nilai seperti persons=2
= −0,52 bermakna relatif terhadap bobot lain dalam grup yang sama. Prediksi dan J tidak terpengaruh.

Keterbatasan. (1) Satu split dan satu seed, tanpa validasi silang atau interval kepercayaan. (2) Data uji 319 sampel: satu sampel mengubah akurasi ±0,31 poin. (3) Dataset deterministik dan mencakup seluruh ruang atribut: data uji adalah kombinasi atribut yang tidak dipakai melatih, bukan sampel populasi mobil nyata, sehingga akurasi tidak boleh dibaca sebagai kinerja di dunia nyata. (4) Hanya dua dari empat kelas. (5) Model linear pada one-hot tidak dapat menyatakan interaksi antar atribut;

keterbatasan ini inheren. (6) Inisialisasi nol dan urutan tetap; 50 epoch belum konvergen untuk ADALINE η kecil. (7) Akurasi latih tinggi tidak menjamin kinerja sempurna pada data baru. **Pengembangan:** fitur interaksi (mis. buying × maint) atau MLP seperti Tugas 1; validasi silang berstrata dan data validasi untuk memilih η dan epoch; penyesuaian ambang untuk menurunkan FP; perluasan ke empat kelas dengan one-vs-rest.

8. Kesimpulan

- Perceptron dan ADALINE berhasil diimplementasikan dengan NumPy untuk klasifikasi unacc vs acc (1.594 observasi, 21 fitur one-hot); hitungan manual dua langkah untuk keduanya cocok dengan kode.
- Data latih **tidak terpisah linear** (linear programming infeasible; Perceptron tidak pernah mencapai nol kesalahan, minimum 89 pembaruan). Model linear pada one-hot tidak menangkap interaksi antar atribut, sehingga akurasi berada di sekitar 0,90–0,95.
- Perceptron memperbarui bobot dari error diskret hanya saat salah; ADALINE dari error linear pada semua sampel dan konvergen mulus ke solusi kuadrat terkecil ($\eta = 0{,}1$: $J = 0{,}1938 = J^*$). Pada data uji ADALINE $\eta = 0{,}1$ (akurasi 0,947; precision 0,875; recall 0,909) memiliki kesalahan berbahaya jauh lebih sedikit (FP = 10) daripada Perceptron (akurasi 0,903; FP = 28).
- η tidak mengubah hasil Perceptron (hanya skala bobot) tetapi menentukan kecepatan penurunan J pada ADALINE. Standardisasi tidak diperlukan untuk mencegah divergensi pada one-hot, tetapi mempercepat konvergensi: tanpa standardisasi ADALINE baru mencapai J^* setelah ±1.000 epoch.
- Akurasi yang sama tidak berarti proses belajar yang sama. Kesimpulan dibatasi oleh satu split, data deterministik, dan hanya dua kelas.

9. Daftar pustaka

Bohanec, M., & Rajkovic, V. (1990). Expert system for decision making. *Sistemica*, 1(1), 145–157. Zupan, B.,

Bohanec, M., Bratko, I., & Demšar, J. (1997). Machine learning by function decomposition.

Proc. ICML-97, 421–429. https://file.biolab.si/biolab/blaz/papers/1997icml.pdf

Bohanec, M., & Zupan, B. *Car Dataset* (halaman dataset dan tabel aturan DEX). https://file.biolab.si/biolab/app/hint/car_dataset.html

Car Evaluation [Dataset]. UCI Machine Learning Repository. https://archive.ics.uci.edu/dataset/19/car+evaluation (CC BY 4.0).

Rosenblatt, F. (1958). The perceptron: A probabilistic model for information storage and organization in the brain. *Psychological Review*, 65(6), 386–408. https://doi.org/10.1037/h0042519

Widrow, B., & Hoff, M. E. (1960). Adaptive switching circuits. *IRE WESCON Convention Record*, Part 4, 96–104. https://isl.stanford.edu/~widrow/papers/c1960adaptiveswitching.pdf

Raschka, S. (tanpa tahun). *Adaline: Adaptive Linear Neuron Classifier*. Dokumentasi mlxtend. https://rasbt.github.io/mlxtend/user_guide/classifier/Adaline/ (diakses 6 Oktober 2026).

Lampiran A. Perhitungan manual pada data mini (η = 0,1, w = 0, b = 0)

Data: $x_1 = (1, 2)$, $y_1 = -1$; $x_2 = (2, 1)$, $y_2 = +1$; $x_3 = (-1, -1)$, $y_3 = -1$; $x_4 = (1, -1)$, $y_4 = +1$.

Sampel	x	y	$z = w^T x + b$	$\hat{y}$	$\Delta = \eta(y - \hat{y})$	w sesudah	b sesudah
1	(1, 2)	−1	0	+1 ($z \geq 0$)	$0{,}1(-1 - 1) = -0{,}2$	(−0,2; −0,4)	−0,2
2	(2, 1)	+1	$-0{,}4 - 0{,}4 - 0{,}2 = -1{,}0$	−1	$0{,}1(1 + 1) = +0{,}2$	(0,2; −0,2)	0

Perceptron: bobot akhir (0,2; −0,2), bias akhir 0.

ADALINE (batch, n = 4). Iterasi 1: z = 0, e = (−1, 1, −1, 1), J = 0,5; $X^T e$ = (3, −1); $X^T e/n$ = (0,75; −0,25); mean(e) = 0 → w = (0,075; −0,025), b = 0; J sesudah = 0,441094. Iterasi 2: z = (0,025; 0,125; −0,05; 0,1), e = (−1,025; 0,875; −0,95; 0,9); $X^T e$ = (2,575; −1,125); $X^T e/n$ = (0,64375; −0,28125); mean(e) = −0,05 → **w = (0,139375; −0,053125), b = −0,005**; J sesudah = 0,393806.

Lampiran B. Perhitungan manual pada dua sampel data mobil nyata (one-hot mentah, η = 0,1, w = 0, b = 0)

	buying	maint	doors	persons	lug_boot	safety	y
Sampel 1	high	vhigh	5more	2	big	low	−1
Sampel 2	high	med	3	more	big	med	+1

Kolom aktif yang dibagi kedua sampel: buying=high dan lug_boot=big. **Perceptron.** Sampel 1: z = 0 → ŷ = +1, salah; Δ = −0,2, sehingga 6 kolom aktif = −0,2 dan b = −0,2. Sampel 2: z = (−0,2) + (−0,2) − 0,2 = −0,6 → ŷ = −1, salah; Δ = +0,2, sehingga 6 kolom aktif sampel 2 naik 0,2 dan b = 0. Bobot akhir: buying=high = lug_boot=big = 0; maint=vhigh = doors=5more = persons=2 = safety=low = −0,2; maint=med = doors=3 = persons=more = safety=med = +0,2; b = 0.

ADALINE (n = 2). Iterasi 1: z = 0, e = (−1, +1), J = 0,5; $X^T e/n = (x_2 - x_1)/2$, sehingga kolom khusus sampel 2 = +0,5, khusus sampel 1 = −0,5, kolom bersama = 0, mean(e) = 0. Dengan η = 0,1: ±0,05, b = 0; z = (−0,2; +0,2), e = (−0,8; +0,8), J = 0,32. Iterasi 2: kolom khusus = $\pm(0{,}05 + 0{,}1 \cdot 0{,}4) = \pm 0{,}09$, kolom bersama tetap 0, b = 0; z = (−0,36; +0,36), e = (−0,64; +0,64), J = 0,2048.

Lampiran C. Bobot dan bias akhir (21 bobot + bias)

Fitur	Perceptron η = 0.01 std.	ADALINE η = 0.1 std.	Perceptron η = 0.01 tanpa std.	ADALINE η = 0.01 tanpa std.
buying=vhigh	-0,0952	-0,0881	-0,1000	-0,0591
buying=high	-0,1081	-0,0200	-0,1200	-0,0352
buying=med	0,0633	0,0535	0,0400	-0,0239
buying=low	0,1549	0,0619	0,1200	-0,0219
maint=vhigh	-0,1498	-0,0971	-0,1600	-0,0584
maint=high	-0,0335	-0,0084	-0,0200	-0,0343
maint=med	0,1057	0,0695	0,0600	-0,0180
maint=low	0,0864	0,0412	0,0600	-0,0294
doors=2	-0,0541	-0,0429	-0,0400	-0,0438
doors=3	-0,0286	0,0043	-0,0400	-0,0339
doors=4	0,0365	0,0069	0,0000	-0,0337
doors=5more	0,0456	0,0316	0,0200	-0,0286
persons=2	-0,5250	-0,2672	-0,4000	-0,1300
persons=4	0,2470	0,1479	0,1600	-0,0029
persons=more	0,2923	0,1267	0,1800	-0,0072
lug_boot=small	-0,0865	-0,0657	-0,1200	-0,0612
lug_boot=med	0,0496	0,0170	0,0200	-0,0412
lug_boot=big	0,0383	0,0498	0,0400	-0,0376
safety=low	-0,5118	-0,2701	-0,3600	-0,1321
safety=med	0,2276	0,0818	0,1000	-0,0192
safety=high	0,3030	0,1993	0,2000	0,0113
bias b	-0,8600	-0,5158	-0,0600	-0,1401

Bobot memakai ruang fitur sesuai konfigurasi (terstandardisasi atau mentah). Bobot one-hot tidak unik (Bagian 7e); bandingkan nilainya dalam satu grup atribut.